

UNIVERSIDADE DE SOROCABA
GRADUAÇÃO EM CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL

VINICIUS FROES DE OLIVEIRA

**Auditoria automatizada através da detecção de equipamentos de proteção individual (EPI)
utilizando YOLO**

Sorocaba

2026

VINICIUS FROES DE OLIVEIRA

**Auditoria automatizada através da detecção de equipamentos de proteção individual (EPI)
utilizando YOLO**

Monografia apresentada à Banca Examinadora do curso de Ciência de Dados e Inteligência Artificial da Universidade de Sorocaba para obtenção do título de Bacharel em Ciência de Dados e Inteligência Artificial.

Orientador: Prof. Dr. Jaime Ranulfo Leite Filho

Sorocaba

2026

Monografia de autoria dos autores supracitados, sob o título “**Auditoria automatizada através da detecção de equipamentos de proteção individual (EPI) utilizando YOLO**”, apresentada à Banca Examinadora do Curso de Ciência de Dados e Inteligência Artificial da Universidade de Sorocaba, para obtenção do título de Bacharel em Ciência de Dados e Inteligência Artificial, aprovada em ____ de _____ de _____ pela comissão julgadora constituída pelos doutores:

Prof. Me. Dr. Denicezar Angelo Baldo
Universidade de Sorocaba
Presidente

Prof. Me. Dr. Jaime Ranulfo Leite Filho
Universidade de Sorocaba
Avaliador

Prof. Me. Dr. Alex Frazatti Silva
Universidade de Sorocaba
Avaliador

Agradecimentos

A realização desta monografia representa um marco significativo em nossas trajetórias acadêmicas e profissionais. Este trabalho não teria sido possível sem o apoio e a colaboração de diversas pessoas e instituições, às quais expressamos nossa profunda gratidão.

Primeiramente, agradecemos ao nosso orientador, Professor Dr. Jaime Ranulfo Leite Filho, cuja orientação precisa e incentivo constante foram essenciais para o desenvolvimento desta pesquisa. Sua expertise e dedicação proporcionaram uma base sólida para que eu pudesse explorar e aprofundar meus conhecimentos em visão computacional e detecção de objetos.

Agradecemos também à Universidade de Sorocaba, por fornecer os recursos e o ambiente propício para a realização deste trabalho. Aos colegas e amigos do laboratório de Análise e Desenvolvimento de Sistema, obrigado pelas discussões enriquecedoras, pelo apoio técnico e pela camaradagem durante todo o processo.

Não poderíamos deixar de mencionar as nossas famílias, que sempre acreditaram em nós e nos apoiaram incondicionalmente. Aos nossos pais, pelo amor e suporte emocional, e aos nossos amigos, pela compreensão nos momentos de ausência e pelas palavras de encorajamento.

Por fim, agradecemos a todos que, direta ou indiretamente, contribuíram para a concretização desta monografia. A todos vocês, nossa sincera gratidão.

Esperamos que este trabalho possa servir de base para futuras pesquisas e que as contribuições aqui apresentadas possam ajudar no avanço do conhecimento na área de visão computacional.

Com gratidão,

Autores

“In God we trust. All others must bring data”

Edwards Deming

Resumo

Auditoria automatizada através da detecção de equipamentos de proteção individual (EPI) utilizando YOLO. 2026. 55 f. Projeto acadêmico – Graduação em Ciência de Dados e Inteligência Artificial, Universidade de Sorocaba, São Paulo, 2026.

Com o avanço das tecnologias e a crescente necessidade de garantir a segurança em ambientes de trabalho, torna-se essencial desenvolver métodos automatizados para monitoramento do uso de Equipamentos de Proteção Individual (EPI). No setor da construção civil, essa necessidade se torna ainda mais evidente, devido ao alto índice de acidentes e à exposição constante a riscos. Atualmente, a fiscalização do uso desses equipamentos é realizada, em grande parte, de forma manual, exigindo tempo, atenção constante e estando sujeita a falhas humanas.

O objetivo deste trabalho é utilizar técnicas de visão computacional para identificar automaticamente a presença ou ausência de EPIs em trabalhadores da construção civil, com foco na auditoria e análise de conformidade. Busca-se desenvolver um modelo capaz de detectar equipamentos como capacetes, coletes, máscaras, botas e luvas de segurança em registros visuais (imagens estáticas). A implementação desta prova de conceito visa criar uma ferramenta automatizada que permita analisar eventos passados, identificando infrações de segurança para embasar ações corretivas, treinamentos e auditorias, evitando a reincidência de comportamentos de risco e garantindo a conformidade com as normas de segurança.

Além disso, este trabalho visa melhorar a eficiência operacional e contribuir para a redução de acidentes de trabalho, promovendo maior segurança. Para a execução do projeto, serão utilizadas imagens públicas contendo trabalhadores com e sem o uso de EPIs, possibilitando a análise e validação do modelo desenvolvido.

A implementação técnica do projeto será realizada em Python, com o suporte de plataformas de computação em nuvem como o **Google Colab**, que viabiliza o treinamento de modelos de machine learning. A metodologia envolverá o desenvolvimento e a avaliação de modelos de *deep learning* para detecção de objetos. Serão investigadas diferentes arquiteturas, dando ênfase inicial a detectores de estágio único (*single-stage*) como a família de modelos **YOLO (You Only Look Once)**, reconhecidos por seu excelente balanço entre velocidade e precisão, ideais para uma prova de conceito.

Durante o desenvolvimento, podem surgir desafios como variações de iluminação, ângulos das imagens, resolução das imagens, oclusão parcial dos equipamentos e diferentes contextos de trabalho, que podem dificultar a identificação correta dos EPIs, além das limitações de hardware, uma vez que o Google Colab disponibiliza gratuitamente apenas a GPU Nvidia T4 de 16 GB. Apesar disso, espera-se que o sistema seja capaz de apresentar resultados consistentes, contribuindo para a automação da segurança no ambiente de trabalho e atuando de forma preventiva na redução de riscos.

Palavras-chave: Visão computacional. Construção civil. EPI. Segurança do trabalho. Detecção de objetos. Inteligência artificial.

Abstract

Automated Audit through Detection of Personal Protective Equipment (PPE) using YOLO. 2026. 55 f. Academic Project – Bachelor's Degree in Data Science and Artificial Intelligence, Universidade de Sorocaba, São Paulo, 2026.

With the advancement of technologies and the growing need to ensure safety in work environments, it becomes essential to develop automated methods for monitoring the use of Personal Protective Equipment (PPE). In the civil construction sector, this need is even more evident due to the high rate of accidents and constant exposure to risks. Currently, the inspection of these equipments is mostly carried out manually, requiring time, constant attention, and being subject to human error.

The objective of this work is to use computer vision techniques to automatically identify the presence or absence of PPE on construction workers, with a focus on auditing and compliance analysis. The aim is to develop a model capable of detecting equipment such as helmets, vests, masks, boots, and safety gloves in visual records (static images). The implementation of this proof of concept seeks to create an automated tool that allows the analysis of past events, identifying safety violations to support corrective actions, training, and audits, thus preventing the recurrence of risky behaviors and ensuring compliance with safety standards.

Furthermore, this study aims to improve operational efficiency and contribute to the reduction of workplace accidents, promoting greater safety. For the execution of the project, publicly available images containing workers with and without the use of PPE will be used, enabling the analysis and validation of the developed model.

The technical implementation of the project will be carried out in Python, with the support of cloud computing platforms such as **Google Colab**, which enables the training of machine learning models. The methodology will involve the development and evaluation of *deep learning* models for object detection. Different architectures will be investigated, with an initial emphasis on single-stage detectors such as the **YOLO (You Only Look Once)** family of models, recognized for their excellent balance between speed and accuracy, ideal for a proof of concept.

During development, challenges may arise such as variations in lighting, image angles, image resolution, partial occlusion of equipment, and different work contexts, which can hinder the correct identification of PPE, in addition to hardware limitations, since Google Colab provides for free only the NVIDIA T4 GPU with 16 GB. Despite this, it is expected that the system will be able to deliver consistent results, contributing to the automation of safety in the work environment and acting preventively in risk reduction.

Keywords: Computer vision. PPE. Construction safety. Object detection. Deep learning.

Lista de figuras

Figura 1 – Exemplo de representação de imagens	19
Figura 2 – Exemplo de pré-processamento de imagem	20
Figura 3 – Exemplo de segmentação de imagens	22
Figura 4 – Exemplo de extração de características	23
Figura 5 – Exemplo de transformações geométricas - projeção em perspectiva	25
Figura 6 – Exemplo de reconhecimento de padrões em imagens	26
Figura 7 – Exemplo de análise morfológica	27
Figura 8 – Exemplo de aplicações avançadas em processamento de imagens	29
Figura 9 – Exemplo de escala de cinza	32
Figura 10 – Exemplo de suavização de imagem	32
Figura 11 – Exemplo de limiarização	33
Figura 12 – Exemplo de detecção de bordas	33
Figura 13 – Exemplo de detecção de contornos	34
Figura 14 – Gráfico comparativo de versões do yolo26	35
Figura 15 – Fluxo das atividades do experimento	37
Figura 16 – Modelo Teórico para detecção de EPIs	38
Figura 17 – Imagem original utilizada no experimento	41
Figura 18 – Redimensionamento com técnica Letterbox	42
Figura 19 – Variação de iluminação HSV	43
Figura 20 – Flip horizontal e Escala	44
Figura 21 – Efeito music (multi-amstras)	45
Figura 22 – Imagem de resultado com caixas delimitadoras	46
Figura 23 – Matriz de confusão	48
Figura 24 – Curvas de treinamento e validação (Loss)	50

Lista de algoritmos

Algoritmo 1 – Pipeline de detecção de EPIs	39
--	----

Lista de quadros

Quadro 1 – Representação de imagens	19
Quadro 2 – Pré-processamento de Imagens	21
Quadro 3 – Segmentação de Imagens	22
Quadro 4 – Extração de características	24
Quadro 5 – Transformações Geométricas	25
Quadro 6 – Reconhecimento de padrões de imagens	26
Quadro 7 – Análise Morfológica	28
Quadro 8 – Aplicações avançadas em processamento de imagens	29

Lista de tabelas

Tabela 1 – Métricas de desempenho do modelo YOLO por classe 46

Lista de abreviaturas e siglas

AR	Augmented Reality.
CBH	Contagem Base Humana.
CH	Contagem Humana.
CMYK	Cyan, Magenta, Yellow e Key.
CNN	Convolutional Neural Network.
HSV	Hue, Saturation, Value.
JPEG	Joint Photographic Experts Group.
LDA	Linear Discriminant Analysis.
PCA	Principal Component Analysis.
PNG	Portable Network Graphic.
RGB	Red, Green e Blue.
TIFF	Tag Image File Format.
VR	Virtual Reality.

Sumário

1	Introdução	14
1.1	Motivação	14
1.2	Objetivos	15
1.3	Estrutura do trabalho	16
2	Conceitos fundamentais	17
2.1	Considerações iniciais	17
2.2	Processamento de imagens	18
2.2.1	Representação de Imagens	18
2.2.2	Pré-processamento de Imagens	20
2.2.3	Segmentação de Imagens	21
2.2.4	Extração de Características	22
2.2.5	Transformações Geométricas	24
2.2.6	Reconhecimento de Padrões em Imagens	26
2.2.7	Análise Morfológica	27
2.2.8	Aplicações Avançadas em Processamento de Imagens	28
2.3	Considerações finais do capítulo	30
3	Deteção de objetos	31
3.1	Considerações iniciais	31
3.2	Técnicas de deteção de objetos	31
3.2.1	Abordagens clássicas	31
3.2.2	Limitações das abordagens clássicas	34
3.2.3	Modelos baseados em Deep Learning	34
3.3	Limitações e desafios	35
3.4	Oportunidades	36
4	Materiais e Métodos	37
4.1	Protocolo experimental	37
4.2	Definição do modelo teórico	38
4.3	Diretrizes para captura de imagens	38

4.4	<i>Implementação do algoritmo de detecção de EPIs</i>	38
4.5	<i>Validação do modelo</i>	39
4.6	<i>Considerações finais do capítulo</i>	39
5	Resultados experimentais	40
5.1	<i>Considerações iniciais</i>	40
5.2	<i>Protocolo Experimental</i>	40
5.2.1	<i>Pipeline de Processamento e Data Augmentation</i>	40
5.3	<i>Validação do Modelo</i>	46
5.4	<i>Interpretação da tabela</i>	47
5.5	<i>Matriz de confusão</i>	47
5.6	<i>Interpretação da matriz</i>	48
5.7	<i>Curvas de treinamento e validação (Loss)</i>	49
5.8	<i>Interpretação das curvas de treinamento e validação (Loss)</i>	50
6	Conclusões	52
6.1	<i>Limitações</i>	52
6.2	<i>Trabalhos futuros</i>	53
	REFERÊNCIAS	54

1 Introdução

A segurança do trabalho é um dos pilares fundamentais em ambientes industriais, logísticos e operacionais, sendo essencial para a prevenção de acidentes e a preservação da integridade física dos trabalhadores. Nesse contexto, o uso adequado de Equipamentos de Proteção Individual (EPI) é uma exigência normativa e uma prática indispensável para a redução de riscos ocupacionais.

Dentre os diversos setores produtivos, a construção civil se destaca como uma das áreas com maior índice de acidentes de trabalho, devido à exposição constante a riscos físicos, mecânicos e ambientais. Nesse cenário, o uso de EPIs como capacetes e coletes refletivos, máscaras, luvas e botas de segurança torna-se essencial para garantir a segurança dos trabalhadores.

Com o avanço das tecnologias de inteligência artificial, a visão computacional tem se destacado como uma ferramenta promissora na automação de processos de monitoramento e fiscalização. Essa área permite que sistemas computacionais interpretem imagens e vídeos de forma automática, possibilitando aplicações de automação de fiscalização com maior eficiência e precisão.

Diante disso, este trabalho propõe o desenvolvimento de um sistema capaz de automatizar a fiscalização do uso de EPIs em trabalhadores da construção civil, contribuindo para a melhoria das condições de segurança no ambiente de trabalho por meio da garantia da conformidade com as normas de segurança e da redução de falhas humanas no processo de fiscalização.

1.1 Motivação

Em ambientes de trabalho que envolvem riscos, como a construção civil, o uso correto de Equipamentos de Proteção Individual é essencial para evitar acidentes. No entanto, a fiscalização desse uso é frequentemente realizada de forma manual, o que pode resultar em falhas, inconsistências e baixa eficiência, especialmente em locais com grande número de trabalhadores.

Além disso, muitos trabalhadores, mesmo iniciando suas atividades com os EPIs adequados, podem removê-los ao longo do tempo, comprometendo a própria segurança. Esse tipo de comportamento é difícil de ser monitorado continuamente por métodos tradicionais.

Nesse cenário, a automação desse processo por meio de tecnologias de visão computacional surge como uma solução viável e eficiente. A utilização de sistemas automatizados permite a auditoria de grandes volumes de imagens e registros visuais de forma rápida e padronizada. Isso auxilia na identificação retrospectiva de trabalhadores que não utilizaram corretamente os equipamentos de proteção, fornecendo aos gestores de segurança dados concretos para a aplicação de medidas corretivas, treinamentos direcionados e auditorias.

Dessa forma, é possível reduzir riscos, melhorar a fiscalização e aumentar a segurança no ambiente de trabalho.

1.2 Objetivos

O objetivo geral deste trabalho é desenvolver um sistema capaz de identificar e monitorar automaticamente o uso de Equipamentos de Proteção Individual em trabalhadores da construção civil por meio de técnicas de visão computacional.

Para atingir esse objetivo, foram definidos os seguintes objetivos específicos:

1. Coletar e organizar um conjunto de dados de imagens estáticas contendo trabalhadores da construção civil com e sem o uso de EPIs (capacetes, coletes, máscaras, luvas e botas de segurança).
2. Desenvolver e aplicar técnicas de pré-processamento nas imagens para adequá-las ao treinamento do modelo.
3. Treinar e aplicar modelos de visão computacional (como a arquitetura YOLO) para detectar a presença ou ausência dos equipamentos nas imagens.
4. Avaliar o desempenho do modelo por meio de métricas padrão utilizadas em detecção de objetos (como mAP50, mAP50-95, Recall e Box(p)).
5. Validar a viabilidade do sistema como uma ferramenta de auditoria automatizada para análise de conformidade de segurança (análise pós-evento).

1.3 Estrutura do trabalho

Este trabalho, além da Introdução apresentada no Capítulo 1, está organizado da seguinte forma:

Capítulo 2 - Aspectos conceituais: apresenta os principais conceitos relacionados à visão computacional e segurança do trabalho.

Capítulo 3 - Detecção de objetos: aborda métodos e técnicas utilizados na identificação de objetos em imagens, com foco na detecção de EPIs na Área da Construção Civil.

Capítulo 4 - Materiais e métodos: descreve a metodologia adotada, incluindo coleta de dados, pré-processamento e aplicação dos modelos.

Capítulo 5 - Resultados experimentais: apresenta os resultados obtidos com a implementação do sistema proposto.

Capítulo 6 - Conclusões: discute as conclusões do trabalho e possíveis melhorias futuras.

Por fim, são apresentadas as Referências que fundamentam teoricamente a pesquisa desenvolvida.

2 Conceitos fundamentais

2.1 Considerações iniciais

A visão computacional é uma área da ciência da computação que busca desenvolver métodos e técnicas capazes de permitir que sistemas computacionais interpretem e compreendam imagens e vídeos de forma semelhante à percepção humana. Essa área envolve a aplicação de algoritmos matemáticos e modelos computacionais para a extração de informações relevantes a partir de dados visuais.

Os primeiros estudos relacionados à visão computacional tiveram início por volta da década de 1950, quando pesquisadores buscavam desenvolver sistemas capazes de identificar formas geométricas simples e realizar classificações básicas de objetos. Nessa fase inicial, foram utilizadas as primeiras abordagens baseadas em redes neurais, ainda bastante limitadas em termos de capacidade computacional e precisão.

Na década de 1970, a visão computacional passou a ser aplicada em contextos comerciais pela primeira vez, com destaque para sistemas de reconhecimento de caracteres, conhecidos como OCR (Optical Character Recognition). Esses sistemas tinham como objetivo interpretar textos manuscritos e digitados, sendo utilizados, inclusive, como ferramentas de apoio para pessoas com deficiência visual.

Com o avanço da tecnologia e, principalmente, com a popularização da internet a partir da década de 1990, houve um aumento significativo na disponibilidade de imagens digitais. Esse crescimento impulsionou o desenvolvimento de novas técnicas de análise de imagens, possibilitando avanços importantes em áreas como reconhecimento facial, detecção de objetos e análise de vídeo.

Nos últimos anos, com a evolução do aprendizado de máquina e do aprendizado profundo (deep learning), a visão computacional passou a alcançar níveis de desempenho cada vez mais elevados, permitindo que sistemas sejam capazes de identificar padrões complexos em imagens com alta precisão. Atualmente, essas tecnologias são amplamente utilizadas em diversas aplicações, como segurança, medicina, automação industrial e monitoramento inteligente.

No contexto deste trabalho, a visão computacional será aplicada na detecção do uso de Equipamentos de Proteção Individual (EPI) em trabalhadores da construção civil, permitindo identificar automaticamente a presença, ausência de itens como capacetes, coletes de segurança, máscara, luvas e botas de segurança. Essa aplicação demonstra o potencial da área na resolução

de problemas reais, especialmente no que se refere à fiscalização do uso de EPIs e à melhoria da segurança no ambiente de trabalho.

Dessa forma, a visão computacional se apresenta como uma ferramenta essencial para o desenvolvimento de sistemas inteligentes capazes de interpretar o ambiente visual e auxiliar na tomada de decisões automatizadas (WECHSLER, 2014).

2.2 *Processamento de imagens*

O processamento de imagens é uma área da ciência da computação que envolve a manipulação, análise e interpretação de imagens digitais. Essa técnica utiliza algoritmos e métodos matemáticos para realizar operações como melhoria de qualidade, detecção de padrões, segmentação e reconhecimento de objetos (GONZALEZ; WOODS, 2008).

O objetivo principal do processamento de imagens é extrair informações relevantes a partir dos dados visuais, permitindo que sistemas computacionais interpretem o conteúdo de uma imagem de forma automatizada. Para isso, são aplicadas técnicas que transformam a imagem original em representações mais adequadas para análise.


O processamento de imagens pode ser dividido em diferentes etapas, incluindo aquisição da imagem, pré-processamento, extração de características e reconhecimento de padrões. Cada uma dessas etapas desempenha um papel fundamental no desenvolvimento de sistemas baseados em visão computacional.

O processamento de imagens possui aplicações em diversas áreas, como medicina, segurança e automação industrial (KHAN; ANWAR; MAJID, 2021). No contexto deste trabalho, essas técnicas serão utilizadas para auxiliar na identificação do uso de Equipamentos de Proteção Individual em trabalhadores da construção civil, permitindo analisar automaticamente a presença ou ausência no uso dos equipamentos.

2.2.1 *Representação de Imagens*

A representação de imagens é uma etapa fundamental no processamento de imagens e na aplicação de algoritmos de aprendizado de máquina, conforme ilustrado na Figura 1 e no Quadro 1.

Figura 1 – Exemplo de representação de imagens



Fonte – Google Images (2024)

Na Figura 1, observa-se o processo de transformação de uma imagem analógica em uma representação digital. Inicialmente, tem-se a imagem original (a), que passa por um processo de amostragem, sendo convertida em uma matriz bidimensional (b). Em seguida, ocorre a quantização (c), na qual os níveis de intensidade de cada ponto da imagem são convertidos em valores numéricos discretos. Esse processo permite que a imagem seja armazenada e processada por sistemas computacionais, possibilitando sua utilização em aplicações de visão computacional, como a detecção de Equipamentos de Proteção Individual em trabalhadores da construção civil.

Quadro 1 – Representação de imagens

N.	Técnica	Descrição
01	Modelos de representação de imagens	As imagens são comumente representadas como matrizes bidimensionais, onde cada elemento (<i>pixel</i>) corresponde ao valor de intensidade ou cor de uma posição específica. Além disso, também podem ser representadas como vetores de características, que consistem em representações compactas contendo informações relevantes para determinadas tarefas, reduzindo a necessidade de utilizar todos os <i>pixels</i> da imagem (GONZALEZ; WOODS, 2008).
02	Espaços de cores	O modelo de cor Red, Green e Blue (RGB) é o mais utilizado em imagens digitais, representando cores a partir das componentes vermelho, verde e azul. Cada <i>pixel</i> é definido pela combinação dessas três cores. O modelo Cyan, Magenta, Yellow e Key (CMYK) é amplamente utilizado em sistemas de impressão, enquanto o modelo Hue, Saturation, Value (HSV) representa as cores de acordo com a percepção humana, utilizando os parâmetros matiz, saturação e valor (????).
03	Resolução e formatos de imagem	A resolução determina o nível de detalhe de uma imagem. Formatos como Joint Photographic Experts Group (JPEG) são amplamente utilizados devido à sua compressão eficiente, enquanto o Portable Network Graphic (PNG) é indicado para imagens com transparência. Já o formato Tag Image File Format (TIFF) é utilizado em aplicações que exigem alta qualidade, como edição profissional e publicações (??).

2.2.2 Pré-processamento de Imagens

O pré-processamento de imagens é uma etapa fundamental no processamento de dados visuais antes de sua utilização em modelos de aprendizado de máquina ou em algoritmos de visão computacional. Essa etapa tem como objetivo melhorar a qualidade das imagens e padronizar os dados de entrada, facilitando a extração de informações relevantes.

As principais técnicas de pré-processamento incluem ajuste de iluminação, remoção de ruídos, redimensionamento e normalização das imagens. Essas operações permitem reduzir variações indesejadas e tornar os dados mais adequados para análise.

A Figura 2 e o Quadro 2 apresentam exemplos de técnicas utilizadas no pré-processamento de imagens.

Figura 2 – Exemplo de pré-processamento de imagem



Fonte – Google Images (2024)

Na Figura 2, observa-se o processo de equalização de histograma aplicado à imagem Lena. A imagem original (a) passa por diferentes métodos de equalização, resultando em versões

com melhor distribuição de intensidade e contraste (b–f). Esse tipo de técnica é amplamente utilizado para melhorar a visibilidade de detalhes em imagens, sendo especialmente importante em aplicações reais, como a fiscalização de trabalhadores em ambientes de construção civil, onde condições de iluminação podem variar significativamente.

Quadro 2 – Pré-processamento de Imagens

N.	Técnica	Descrição
01	Redimensionamento, rotação e recorte	O redimensionamento altera as dimensões da imagem, sendo essencial para adequação ao modelo. A rotação corrige orientações e amplia a variabilidade dos dados. O recorte permite focar regiões de interesse, reduzindo informações irrelevantes (GONZALEZ; WOODS, 2008).
02	Correção de iluminação e contraste	Ajustes de iluminação e contraste são utilizados para melhorar a qualidade visual das imagens. Um bom contraste facilita a identificação de padrões e objetos presentes na cena (QI <i>et al.</i> , 2022).
03	Remoção de ruídos e artefatos	A remoção de ruídos visa eliminar distorções indesejadas que podem comprometer a análise da imagem, aumentando a qualidade dos dados utilizados (QI <i>et al.</i> , 2022).


No contexto deste trabalho, o pré-processamento será aplicado para preparar as imagens utilizadas na detecção de Equipamentos de Proteção Individual em trabalhadores da construção civil, garantindo maior consistência e melhor desempenho do modelo de visão computacional.

2.2.3 Segmentação de Imagens

A segmentação de imagens é uma técnica fundamental no processamento de imagens que tem como objetivo identificar e separar regiões de interesse dentro de uma imagem. Essa técnica permite dividir a imagem em partes significativas, facilitando a análise e o reconhecimento de objetos.

A segmentação é amplamente utilizada em aplicações de visão computacional, pois possibilita isolar elementos relevantes, eliminando informações desnecessárias do fundo da imagem. A Figura 3 e o Quadro 3 apresentam exemplos de técnicas de segmentação.

Figura 3 – Exemplo de segmentação de imagens



Fonte – Google Images (2024)

Na Figura 3, observa-se um exemplo de segmentação aplicado a uma imagem contendo plantas com flores. Inicialmente, tem-se a imagem original (1º). Em seguida, é aplicada uma técnica de filtragem (2º), com o objetivo de destacar regiões de interesse. Por fim, obtém-se a imagem segmentada (3º), na qual os elementos principais são isolados do restante da cena. Em aplicações reais, como na fiscalização de trabalhadores em canteiros de obras, a segmentação pode auxiliar na separação de indivíduos e dos Equipamentos de Proteção Individual presentes na cena.

Quadro 3 – Segmentação de Imagens

N.	Técnica	Descrição
01	Métodos de limiarização	A limiarização consiste em separar os pixels da imagem com base em um valor de intensidade. Pode ser classificada em limiarização global, onde um único valor é aplicado a toda a imagem; limiarização local, onde diferentes regiões utilizam valores distintos; e limiarização adaptativa, que ajusta automaticamente os valores de acordo com as características da imagem (??).
02	Crescimento de regiões e detecção de bordas	O crescimento de regiões é uma técnica que agrupa pixels com características semelhantes a partir de pontos iniciais chamados <i>seed pixels</i> . Já a detecção de bordas busca identificar mudanças abruptas na intensidade dos pixels, permitindo destacar contornos dos objetos presentes na imagem (ASSISTANT, 2024).

No contexto deste trabalho, a segmentação de imagens contribui para destacar regiões onde podem estar presentes os Equipamentos de Proteção Individual em trabalhadores da construção civil, auxiliando o modelo de visão computacional na identificação dos objetos de interesse.


2.2.4 Extração de Características

A extração de características é uma etapa fundamental no processamento de imagens e em sistemas de visão computacional. Essa etapa tem como objetivo identificar e selecionar

informações relevantes presentes na imagem, permitindo que o modelo consiga diferenciar objetos e padrões de forma eficiente.

Em tarefas de visão computacional, a extração de características possibilita transformar dados brutos (pixels) em representações mais significativas, facilitando a análise e a tomada de decisão automatizada. A Figura 4 e o Quadro 4 apresentam exemplos desse processo.

Figura 4 – Exemplo de extração de características



Fonte – Google Images (2024)

Na Figura 4, observa-se um exemplo de *pipeline* de processamento de imagens. Inicialmente, tem-se a imagem de entrada (a), seguida pelo redimensionamento (b), etapa importante para padronizar os dados. Em seguida, ocorre a extração de características (c), onde são identificadas informações relevantes da imagem. Por fim, são detectados diferentes padrões (d), permitindo a interpretação do conteúdo visual. Em aplicações reais, como na fiscalização de trabalhadores em canteiros de obras, esse processo permite identificar padrões visuais associados aos Equipamentos de Proteção Individual.

Quadro 4 – Extração de características

N.	Técnica	Descrição
01	Identificação e seleção de características relevantes	A seleção de características consiste em identificar quais informações são mais importantes para a análise da imagem. Essa etapa permite reduzir a complexidade dos dados e melhorar o desempenho dos modelos de visão computacional (PIEMONTEZ, 2022).
02	Descritores de imagem	Os descritores de imagem representam características visuais relevantes, como cor, textura e forma. Eles permitem transformar os pixels em informações estruturadas, facilitando o reconhecimento de padrões e objetos (SERVICES, 2024).
03	Técnicas de redução de dimensionalidade	A redução de dimensionalidade é utilizada para simplificar os dados, mantendo apenas as informações mais importantes. Técnicas como Principal Component Analysis (PCA) e Linear Discriminant Analysis (LDA) são amplamente utilizadas para reduzir a complexidade e melhorar a eficiência dos modelos (ABDI, 2010; SHU; WU; SUGANTHAN, 2018).


No contexto deste trabalho, a extração de características está relacionada à identificação de padrões visuais associados aos Equipamentos de Proteção Individual em trabalhadores da construção civil, como formato e cor de capacetes e coletes de segurança, máscaras, luvas e botas de segurança. Em modelos baseados em aprendizado profundo, como o YOLO, essa etapa é realizada automaticamente pela rede neural, permitindo maior eficiência, precisão e suporte na identificação do uso dos equipamentos.

2.2.5 Transformações Geométricas

As transformações geométricas desempenham um papel fundamental na área de visão computacional, permitindo modificar a posição, orientação e escala dos objetos em uma imagem. Essas transformações são amplamente utilizadas para ajustar, modelar e preparar imagens para análise, contribuindo para melhorar a qualidade dos dados e a eficiência dos algoritmos.

Além disso, essas técnicas são importantes para tornar os modelos mais robustos, permitindo que reconheçam objetos mesmo quando estão em diferentes posições, tamanhos ou ângulos. A Figura 5 e o Quadro 5 apresentam exemplos dessas transformações.

Figura 5 – Exemplo de transformações geométricas - projeção em perspectiva



Fonte – Google Images (2024)

A Figura 5 ilustra o modelo de projeção em perspectiva de uma câmera, evidenciando como objetos tridimensionais são projetados em um plano bidimensional. Esse modelo é essencial para compreender como imagens são formadas e interpretadas por sistemas computacionais, especialmente em aplicações reais como a fiscalização de trabalhadores em ambientes de construção civil.

Quadro 5 – Transformações Geométricas

N.	Técnica	Descrição
01	Translação, rotação, escala e cisalhamento	A transformação de escala altera o tamanho do objeto. A rotação modifica sua orientação em torno de um ponto fixo. A translação desloca o objeto no plano da imagem. Já o cisalhamento provoca uma distorção ao longo de um eixo (??).
02	Interpolação de <i>pixels</i>	A interpolação consiste em estimar valores de novos pixels a partir de pixels vizinhos, sendo amplamente utilizada em redimensionamento e transformação de imagens (??).
03	Transformada de Hough	Técnica utilizada para detectar padrões geométricos, como linhas e formas, mesmo em situações de ruído ou oclusão parcial (JAMUNDÁ, 2000).


No contexto deste trabalho, as transformações geométricas são relevantes para o pré-processamento e aumento de dados (*data augmentation*), permitindo gerar variações das imagens de entrada. Isso contribui para que o modelo de visão computacional seja capaz de identificar corretamente os Equipamentos de Proteção Individual em trabalhadores da construção civil em diferentes posições, ângulos e condições visuais.

2.2.6 Reconhecimento de Padrões em Imagens

O reconhecimento de padrões em imagens é uma área fundamental da visão computacional, responsável por identificar, interpretar e classificar informações presentes em dados visuais. Essa etapa permite que sistemas computacionais reconheçam automaticamente objetos, padrões e características relevantes em imagens digitais.

Essa técnica é amplamente utilizada em diversas aplicações, como reconhecimento facial, análise de imagens médicas, monitoramento de segurança e automação industrial. A Figura 6 e o Quadro 6 apresentam exemplos de aplicações e técnicas utilizadas nesse processo.

Figura 6 – Exemplo de reconhecimento de padrões em imagens



Fonte – Google Images (2024)

Na Figura 6, observa-se a aplicação de técnicas de visão computacional para detecção e reconhecimento de objetos. O sistema é capaz de identificar diferentes elementos na imagem, localizando-os e classificando-os automaticamente com base em seus padrões visuais.

Quadro 6 – Reconhecimento de padrões de imagens

N.	Técnica	Descrição
01	Classificação de imagens	A classificação de imagens consiste na atribuição de rótulos a imagens com base em seu conteúdo visual. Essa técnica permite identificar automaticamente objetos e padrões presentes nas imagens (JAMUNDá, 2000).
02	Convolutional Neural Network (CNN)	As redes neurais convolucionais (CNN) são amplamente utilizadas em tarefas de visão computacional. Elas são capazes de aprender automaticamente características relevantes a partir das imagens, permitindo alta precisão na identificação de padrões (IBM, 2024).
03	Métodos de avaliação de desempenho	A avaliação de modelos de reconhecimento de padrões é realizada por meio de métricas como matriz de confusão, precisão, recall e F1-score, que permitem analisar o desempenho do modelo (??).

No contexto deste trabalho, o reconhecimento de padrões será realizado por meio de modelos de detecção de objetos baseados em aprendizado profundo, como o YOLO. Esses

modelos permitem identificar automaticamente a presença ou ausência de Equipamentos de Proteção Individual, classificando os objetos identificados nos trabalhadores.


Dessa forma, o reconhecimento de padrões é uma etapa essencial para que o sistema proposto seja capaz de interpretar as imagens e gerar resultados confiáveis.

2.2.7 Análise Morfológica

A análise morfológica refere-se ao estudo da forma e estrutura dos objetos em imagens digitais, sendo amplamente utilizada no processamento de imagens para modificar e analisar regiões específicas. Essa abordagem utiliza operações matemáticas aplicadas sobre os pixels da imagem, permitindo destacar, segmentar e refinar objetos de interesse.

As operações morfológicas são especialmente úteis em imagens binárias ou em tons de cinza, sendo utilizadas para remover ruídos, preencher lacunas e melhorar a definição das estruturas presentes na imagem. A Figura 7 e o Quadro 7 apresentam exemplos dessas técnicas.

Figura 7 – Exemplo de análise morfológica



Fonte – Google Images (2024)

Na Figura 7, observa-se a aplicação de operações morfológicas para realçar e modificar estruturas presentes na imagem. Os elementos estruturantes são utilizados para definir a forma

como as operações atuam sobre os objetos, permitindo destacar regiões específicas conforme o objetivo da análise.

Quadro 7 – Análise Morfológica

N.	Técnica	Descrição
01	Operações morfológicas básicas	As principais operações incluem erosão, que reduz o tamanho dos objetos ao remover pixels das bordas, e dilatação, que expande os objetos ao adicionar pixels. A abertura combina erosão seguida de dilatação, sendo útil para remover ruídos. O fechamento combina dilatação seguida de erosão, permitindo preencher lacunas e conectar regiões (WANGENHEIM, 2000).
02	Esqueletização e afinamento de objetos	A esqueletização consiste em reduzir os objetos a suas estruturas centrais, preservando sua forma essencial. Esse processo é útil para análise de estruturas e pode ser realizado por meio de transformadas específicas (??).
03	Reconstrução morfológica	A reconstrução morfológica utiliza uma imagem marcadora e uma imagem máscara para destacar regiões específicas. Esse processo permite extrair ou enfatizar estruturas relevantes na imagem (GONZALEZ; WOODS, 2008).

No contexto deste trabalho, a análise morfológica pode ser utilizada como técnica complementar no pré-processamento das imagens, auxiliando na melhoria da qualidade visual e na remoção de ruídos. No entanto, o foco principal do sistema proposto está na utilização de modelos baseados em aprendizado profundo, que realizam automaticamente a identificação de padrões relevantes para a detecção de Equipamentos de Proteção Individual.

2.2.8 Aplicações Avançadas em Processamento de Imagens

As aplicações avançadas em processamento de imagens representam um campo em constante evolução, desempenhando um papel essencial em diversas áreas, como medicina, indústria, segurança e entretenimento. Essas aplicações utilizam técnicas sofisticadas de análise de imagens para extrair informações relevantes e apoiar a tomada de decisões automatizadas.

Com o avanço da inteligência artificial e do aprendizado profundo, o processamento de imagens passou a ser aplicado em problemas cada vez mais complexos, permitindo o desenvolvimento de sistemas inteligentes capazes de interpretar o ambiente visual de forma precisa. A Figura 8 e o Quadro 8 apresentam exemplos dessas aplicações.

Figura 8 – Exemplo de aplicações avançadas em processamento de imagens



Fonte – Google Images (2024)

Na Figura 8, observa-se a aplicação do processamento de imagens em diferentes contextos, destacando sua importância em áreas como segurança, indústria e medicina, onde a análise visual automatizada contribui para maior precisão e eficiência.

Quadro 8 – Aplicações avançadas em processamento de imagens

N.	Técnica	Descrição
01	Reconhecimento de objetos	O reconhecimento de objetos consiste na identificação e localização de elementos específicos dentro de uma imagem. Diferentemente da classificação de imagens, essa técnica permite determinar onde os objetos estão posicionados, sendo amplamente utilizada em sistemas de visão computacional (BRADSKI, 2000).
02	Rastreamento de movimento	O rastreamento de movimento permite identificar e acompanhar objetos ao longo de sequências de imagens ou vídeos, sendo aplicado em monitoramento, análise de comportamento e sistemas de vigilância (BRADSKI, 2000).
03	Augmented Reality (AR) e Virtual Reality (VR)	A realidade aumentada (AR) combina elementos virtuais com o ambiente real, enquanto a realidade virtual (VR) cria ambientes totalmente simulados. Ambas as tecnologias utilizam processamento de imagens para gerar experiências interativas e imersivas (??).

No contexto deste trabalho, as aplicações avançadas em processamento de imagens estão diretamente relacionadas à detecção de objetos, especialmente na identificação de Equipamentos de Proteção Individual. O uso de modelos baseados em aprendizado profundo, como o YOLO, permite a detecção desses equipamentos, demonstrando o potencial dessas técnicas em aplicações de fiscalização na segurança no ambiente de trabalho.

2.3 *Considerações finais do capítulo*

Neste capítulo, foram apresentados os principais conceitos relacionados à visão computacional e ao processamento de imagens, fundamentais para o desenvolvimento do sistema proposto.

Foram abordadas técnicas como representação de imagens, pré-processamento, segmentação, extração de características, transformações geométricas e reconhecimento de padrões, evidenciando sua importância na análise e interpretação de dados visuais.

Além disso, foram discutidas aplicações avançadas do processamento de imagens, destacando o uso de modelos baseados em aprendizado profundo para detecção de objetos.

No contexto deste trabalho, essas técnicas servirão como base para o desenvolvimento de um sistema capaz de identificar automaticamente o uso de Equipamentos de Proteção Individual, contribuindo para a automação da fiscalização e auditoria da segurança no ambiente de trabalho.

3 Detecção de objetos

3.1 Considerações iniciais

A detecção de objetos é uma das principais tarefas da visão computacional, sendo responsável por identificar e localizar objetos específicos dentro de imagens ou vídeos. Diferentemente da classificação de imagens, que atribui apenas uma categoria à imagem como um todo, a detecção de objetos permite identificar múltiplos elementos e suas respectivas posições.

O reconhecimento de padrões, nesse contexto, pode ser definido como a capacidade de representar objetos de forma que suas variações sejam consideradas, mantendo ao mesmo tempo eficiência computacional. Isso permite que os sistemas sejam capazes de identificar corretamente os objetos de interesse em diferentes condições visuais ([SANTOS et al., 2020](#)).

No presente trabalho, a detecção de objetos será aplicada na identificação de Equipamentos de Proteção Individual, como capacetes, coletes de segurança, máscaras, luvas e botas de segurança contribuindo para a automação da fiscalização em ambientes de trabalho.

3.2 Técnicas de detecção de objetos


3.2.1 Abordagens clássicas

As técnicas clássicas de detecção de objetos envolvem o uso de métodos baseados em processamento de imagens, como conversão para escala de cinza, suavização, limiarização e detecção de bordas. Essas abordagens são úteis para problemas simples, onde há pouco ruído e alta distinção entre objeto e fundo.

Escala de cinza

A conversão de imagens coloridas para tons de cinza reduz a complexidade dos dados, simplificando o processamento ao utilizar apenas um canal de intensidade ([LUCENA, 2024](#)).

Figura 9 – Exemplo de escala de cinza



Fonte – Google Images (2024)

Suavização

A suavização, também conhecida como *blur*, é utilizada para reduzir ruídos e pequenas variações na imagem, melhorando a eficiência de algoritmos posteriores ([ANTONELLO, 2018](#)).

Figura 10 – Exemplo de suavização de imagem



Fonte – Google Images (2024)

Limiarização e binarização

A limiarização transforma a imagem em uma representação binária, separando os pixels com base em um valor de intensidade. A binarização facilita a identificação de regiões de interesse na imagem ([ANTONELLO, 2018](#); [REDONDA](#); [NASCIMENTO](#); [ASSIS](#),).

Figura 11 – Exemplo de limiarização




Fonte – Google Images (2024)

Detecção de bordas

A detecção de bordas permite identificar mudanças abruptas na intensidade dos pixels, sendo utilizada para destacar contornos de objetos. Algoritmos como Sobel e Canny são amplamente utilizados ([ANTONELLO, 2018](#)).

Figura 12 – Exemplo de detecção de bordas



Fonte – Google Images (2024)

Detecção de contornos

A detecção de contornos permite identificar regiões conectadas na imagem, sendo utilizada para extrair informações como forma e área dos objetos ([RAUBER, 2019](#)).

Figura 13 – Exemplo de detecção de contornos



Fonte – Google Images (2024)

3.2.2 Limitações das abordagens clássicas

Apesar de sua utilidade, as técnicas clássicas apresentam limitações quando aplicadas a problemas mais complexos, como a detecção de Equipamentos de Proteção Individual. Isso ocorre devido a fatores como variação de iluminação, diferentes cores, múltiplos objetos e cenários dinâmicos.

3.2.3 Modelos baseados em Deep Learning

Com o avanço da inteligência artificial, modelos baseados em aprendizado profundo passaram a apresentar melhores resultados na detecção de objetos. Esses modelos são capazes de aprender automaticamente características relevantes diretamente das imagens.

YOLO (You Only Look Once)

O YOLO é uma família de modelos de detecção de objetos que revolucionou a visão computacional desde 2016. A ideia central é processar a imagem uma única vez (one look) para prever caixas delimitadoras, classes e outras informações, tornando-o extremamente rápido comparado aos métodos anteriores baseados em regiões (como R-CNN).


A Ultralytics (empresa mantenedora atual) popularizou e industrializou a série com versões como YOLOv5, YOLOv8, YOLO11 e agora a YOLO26 (lançada em janeiro de 2026), que é a versão mais recente e avançada.

A YOLO26 não representa apenas mais uma atualização incremental na família YOLO, mas sim uma verdadeira mudança de paradigma no desenvolvimento de modelos de detecção de objetos. Enquanto as versões anteriores priorizavam principalmente o desempenho em benchmarks acadêmicos, como o recorde de mAP no conjunto de dados COCO, a YOLO26 foi projetada com foco no deploy prático e no uso real no mundo.

Além disso, a YOLO26 foi profundamente otimizada para dispositivos de borda e de baixo consumo. Ela alcança até 43 por cento mais velocidade em CPU, especialmente nas variantes nano, e entrega excelente desempenho em hardware limitado como Raspberry Pi, NVIDIA Jetson, smartphones e outros equipamentos embarcados. Sua estabilidade após quantização para INT8 e FP16, com perda mínima de precisão, a torna particularmente adequada para aplicações reais como robótica, drones, IoT, vigilância inteligente e automação industrial.

No contexto deste trabalho, o YOLO será utilizado para detectar automaticamente Equipamentos de Proteção Individual, como capacetes, coletes, máscaras, luvas e botas, classificando os trabalhadores de acordo com o a presença dos equipamentos.

Figura 14 – Gráfico comparativo de versões do yolo26



Fonte – Ultralytics, hugging face (2026)

3.3 Limitações e desafios

- **Oclusão de objetos:** Em cenários reais, trabalhadores podem estar parcialmente ocultos por outros objetos ou por outros indivíduos, dificultando a detecção completa dos Equipamentos de Proteção Individual. Isso pode levar a falhas na identificação correta dos EPIs.

- **Falsos positivos:** Elementos presentes no ambiente, como objetos com cores semelhantes aos EPIs, podem ser erroneamente identificados ou não como equipamentos de proteção, afetando a precisão do sistema.
- **Condições de iluminação:** Variações de iluminação, presença de sombras ou ambientes com baixa luminosidade podem impactar significativamente o desempenho do modelo, dificultando a detecção correta dos equipamentos.
- **Variação de ângulo e escala:** Diferenças na posição da câmera, distância e ângulo de captura podem alterar a aparência dos EPIs, tornando a detecção mais desafiadora para o modelo.
- **Objetos pequenos:** Alguns EPIs, como luvas e botas de segurança, apresentam um tamanho reduzido em relação à imagem inteira. Consequentemente, esses objetos dispõem de menos pixels para análise pelo modelo, tornando sua identificação mais difícil.

3.4 Oportunidades

- **Evolução para análise em tempo real:** Embora a prova de conceito atual foque em imagens estáticas para auditoria, uma oportunidade futura de grande impacto é a integração do modelo treinado a fluxos de vídeo de câmeras de segurança, permitindo o monitoramento contínuo e a emissão de alertas instantâneos.
- **Aprimoramento com mais dados, hardware e modelos maiores:** A utilização de conjuntos de dados maiores e mais variados, mais capacidade de hardware e modelos maiores podem melhorar significativamente o desempenho do sistema, tornando-o mais robusto em diferentes cenários.
- **Integração com sistemas de alerta:** O sistema pode ser integrado a mecanismos de alerta automático, notificando quando um trabalhador estiver sem o uso adequado de EPI.


4 Materiais e Métodos

4.1 Protocolo experimental

Primeiro estudamos trabalhos semelhantes ao nosso para escolher os melhores métodos e ferramentas aplicáveis à análise de conformidade no uso de EPIs.

Para a aquisição de imagens, utilizamos *datasets* públicos contendo trabalhadores da construção civil com e sem o uso de capacetes, coletes, máscaras, luvas e botas. No pré-processamento, as imagens foram padronizadas em resolução 640x640 pixels (Por questões de limitação de hardware), mantidas em RGB para preservar informações de cor (essenciais para EPIs refletivos/neon) e submetidas a técnicas de normalização e ajustes de iluminação.

Figura 15 – Fluxo das atividades do experimento




Fonte – Autores (2026)

4.2 Definição do modelo teórico

O modelo teórico adotado consiste em um pipeline de detecção de objetos baseado em redes neurais profundas (deep learning). Foi escolhido o **YOLO26n (Nano)** como modelo principal, por equilibrar velocidade e precisão em hardware limitado.

Figura 16 – Modelo Teórico para detecção de EPIs



Fonte – Autores, 2026

4.3 Diretrizes para captura de imagens

Seguindo o modelo teórico, foram definidas diretrizes para obtenção das melhores imagens:

- Capturar fotos em horários com menor incidência de sombras.
- Garantir que os trabalhadores estejam visíveis em ambientes com iluminação homogênea.
- Evitar ângulos extremos que dificultem a identificação dos EPIs.
- Utilizar câmeras com resolução mínima de 640x640 pixels.

4.4 Implementação do algoritmo de detecção de EPIs

O algoritmo foi implementado em etapas:

Algoritmo 1 Pipeline de detecção de EPIs

- 1: **procedure** DETECCAOEPI
- 2: passo 1 - Aquisição das imagens
- 3: passo 2 - Análise exploratória (EDA)
- 4: passo 3 - Data Augmentation (Mosaic, Scale)
- 5: passo 4 - Treinamento do modelo YOLO26n
- 6: passo 5 - Avaliação do modelo (mAPs, recall e boxP)
- 7: passo 6 - Teste manual (inferência)

Fonte – Autores, 2026

4.5 Validação do modelo

A validação foi definida por meio de uma série de gráficos e tabelas que apresentam as principais métricas do modelo (mAP50, mAP50-95, boxP e Recall), além da matriz de confusão.

4.6 Considerações finais do capítulo

Neste capítulo, apresentamos o fluxo de funcionamento do sistema, o modelo teórico que o fundamenta, os algoritmos utilizados e os procedimentos de validação. A metodologia proposta buscou equilibrar eficiência computacional e eficiência do modelo, garantindo que este seja aplicável em auditorias automatizadas de conformidade no uso de EPIs. Além disso, foram discutidas as diretrizes de captura de imagens e as estratégias de pré-processamento que aumentam a robustez do sistema. Esses elementos fornecem a base para os resultados experimentais apresentados no próximo capítulo.

5 **Resultados experimentais**

5.1 Considerações iniciais

As próximas partes deste trabalho descrevem os métodos empregados, o modelo de detecção utilizado e a análise dos resultados obtidos. Diferentemente de abordagens clássicas baseadas em contornos, este projeto utiliza técnicas modernas de visão computacional com aprendizado profundo, permitindo maior robustez na detecção de Equipamentos de Proteção Individual (EPI).

Serão analisadas as potencialidades e limitações do modelo proposto, evidenciando sua aplicação em cenários reais de monitoramento e segurança no trabalho.

5.2 Protocolo Experimental

Para a realização dos experimentos, será utilizada a linguagem Python (versão 3.11.7), juntamente com bibliotecas como OpenCV (cv2), NumPy, Matplotlib e frameworks de deep learning voltados à detecção de objetos, como o modelo YOLO.

O processo experimental será baseado em um pipeline de treinamento e detecção de objetos, incluindo etapas de preparação dos dados, aumento de dados (*data augmentation*), treinamento do modelo e avaliação dos resultados.

5.2.1 Pipeline de Processamento e Data Augmentation

O objetivo dessas etapas é aumentar a variabilidade dos dados, permitindo que o modelo aprenda a identificar EPIs em diferentes condições reais, como variações de iluminação, escala, posição e contexto.

1. Imagem Original

A imagem original representa o cenário real sem modificações, sendo o ponto inicial para o processamento.

Figura 17 – Imagem original utilizada no experimento



Fonte – Autores, 2026

- Base utilizada para aplicação das técnicas
- Representa condições reais
- Ponto inicial do pipeline

2. Redimensionamento (Letterbox)

Nesta etapa, a imagem é redimensionada para um tamanho padrão (ex.: 640x640), mantendo sua proporção original.

Figura 18 – Redimensionamento com técnica Letterbox



Fonte – Autores, 2026

- Mantém proporção da imagem
- Evita distorção dos EPIs
- Adiciona *padding* quando necessário
- Padroniza entrada do modelo

Essa etapa é fundamental para garantir consistência durante o treinamento do modelo YOLO.

3. Variação HSV

A variação no espaço de cores HSV é utilizada para simular diferentes condições de iluminação.

Figura 19 – Variação de iluminação HSV



Fonte – Autores, 2026

- Ajuste de brilho, saturação e cor
- Simulação de diferentes ambientes
- Redução da dependência de iluminação específica

4. Flip Horizontal e Escala

Essa etapa gera novas variações da imagem através de transformações geométricas.

Figura 20 – Flip horizontal e Escala



Fonte – Autores, 2026

- Espelhamento horizontal
- Simulação de diferentes orientações
- Aplicação de zoom (in/out)
- Representação de diferentes distâncias

5. Mosaic

A técnica Mosaic combina múltiplas imagens em uma única amostra.

Figura 21 – Efeito music (multi-amostras)



Fonte – Autores, 2026

- Combina quatro imagens em uma
- Adiciona mais amostras ao modelo (mais dados)
- Melhora a detecção de objetos pequenos
- Enriquece o contexto visual

6. Resultado do Modelo

Após o treinamento, o modelo é capaz de detectar múltiplos EPIs na mesma cena.

Figura 22 – Imagem de resultado com caixas delimitadoras



Fonte – Autores, 2026

- Detecção eficiente de capacetes e coletes
- Alta confiança em objetos maiores
- Menor desempenho em objetos pequenos (ex.: luvas)
- Boa performance geral do modelo

5.3 Validação do Modelo

A seguir, na Tabela 1, são apresentadas as métricas oficiais de validação do modelo final. Diferente de avaliações subjetivas, o desempenho do algoritmo foi mensurado rigorosamente através das métricas padrão da indústria de visão computacional: Precisão, Revocação (Recall) e mAP (mean Average Precision), calculadas sobre o conjunto de validação.

Tabela 1 – Métricas de desempenho do modelo YOLO por classe

Classe	Instâncias	Precisão	Recall	mAP50	mAP50-95
Capacete	1783	0.920	0.787	0.863	0.563
Máscara	1714	0.915	0.870	0.924	0.638
Colete de Seg.	1393	0.910	0.766	0.844	0.593
Botas	1287	0.791	0.795	0.854	0.552
Luvas	1700	0.869	0.774	0.841	0.533
Média Geral	7877	0.881	0.798	0.865	0.576

Fonte – Autores, 2026

5.4 Interpretação da tabela


- **Alta Precisão Geral e Baixo Índice de Falsos Positivos:** A métrica de Precisão (Precision) indica a confiabilidade do modelo quando ele realiza uma detecção. A média geral de 0.881 (88,1 por cento) demonstra que o sistema é altamente conservador e assertivo: quando o modelo sinaliza a presença de um EPI, há uma probabilidade muito alta de ele estar correto. Destacam-se as classes "Capacete", "Máscara" e "Colete de Segurança", todas ultrapassando a marca de 91 por cento de precisão. Isso comprova que o modelo extraiu com sucesso as características visuais mais fortes desses itens (como cores vibrantes e formatos rígidos), minimizando a ocorrência de falsos alarmes na auditoria.
- **O Equilíbrio da Revocação (Recall) em Objetos Complexos:** A Revocação (Recall) mede a capacidade do modelo de encontrar todos os EPIs existentes na imagem, sem deixar nenhum passar despercebido. A média geral de 0.798 (79,8 por cento) é um resultado extremamente sólido para um ambiente de construção civil. É notável que as classes "Botas" (0.795) e "Luvas" (0.774) mantiveram taxas de Revocação muito próximas à média geral. Este é o reflexo direto das otimizações aplicadas no modelo (como o uso do efeito Mosaic): o modelo aprendeu a localizar objetos pequenos e frequentemente ocluídos com uma eficiência comparável à detecção de objetos grandes e evidentes.
- **Consistência do mAP (mean Average Precision):** O mAP50 é a métrica definitiva para avaliar a qualidade global de um modelo de detecção de objetos, pois ele equilibra a Precisão e a Revocação. Atingir um mAP50 médio de 0.865 (86,5 por cento) em um modelo leve (YOLO Nano) valida completamente a viabilidade técnica do projeto. A consistência é o ponto mais forte aqui: a diferença de mAP50 entre a classe mais fácil (Máscara: 0.924) e a mais difícil (Luvas: 0.841) é de apenas 8,3 pontos percentuais. Isso significa que o modelo não é "viciado" em apenas um tipo de EPI; ele é uma ferramenta de auditoria balanceada e confiável para todos os equipamentos monitorados.

5.5 Matriz de confusão

A Matriz de Confusão gerada após o treinamento final do modelo fornece um diagnóstico visual detalhado sobre a precisão das classificações e os tipos de erros cometidos pela rede

neural. A análise deste gráfico revela a alta robustez do modelo, bem como os desafios inerentes à visão computacional em ambientes industriais complexos.

Figura 23 – Matriz de confusão



Fonte – Autores (2026)

5.6 Interpretação da matriz

- **Alta Capacidade de Discriminação de Classes (A Diagonal Principal):** O aspecto mais notável da matriz é a forte concentração de valores elevados em sua diagonal principal (em azul escuro). Isso indica um alto volume de Verdadeiros Positivos. O modelo demonstrou uma capacidade excepcional de distinguir entre as diferentes classes de EPIs. Observa-se que os erros interclasses são praticamente nulos; ou seja, o modelo não confunde um capacete com um colete, ou uma luva com uma bota. Essa precisão isolada valida a eficácia da arquitetura YOLO na extração correta de características (features) de cada objeto.
- **O Desafio dos Falsos Positivos (Coluna 'Background'):** A coluna mais à direita ilustra as instâncias em que o modelo detectou um objeto onde, na verdade, havia apenas o fundo da imagem (Background). O maior índice de falsos positivos ocorreu na classe Boots (Botas), com 360 predições incorretas. Este comportamento é perfeitamente justificável


pelo contexto do domínio: o chão de um canteiro de obras é repleto de ruído visual, como sombras escuras, pedras, entulhos e poças. O modelo, otimizado para não deixar EPIs passarem despercebidos, ocasionalmente interpreta esses artefatos escuros no solo como calçados de segurança.

- **O Impacto da Oclusão nos Falsos Negativos (Linha 'Background'):** A linha inferior da matriz representa os objetos reais que o modelo não conseguiu detectar, classificando-os erroneamente como fundo (Background). As classes Glove (Luvas) com 327 omissões e Helmet (Capacetes) com 338 omissões lideram esta métrica. Na construção civil, as mãos dos trabalhadores estão em constante movimento, frequentemente segurando ferramentas, cobertas por materiais ou dentro de bolsos, gerando oclusão severa. Da mesma forma, capacetes podem ser ocultados por estruturas metálicas ou capturados em ângulos extremos. Apesar dessas omissões pontuais, a taxa de acerto continua substancialmente superior à taxa de erro.

5.7 *Curvas de treinamento e validação (Loss)*

Os gráficos de treinamento e validação representam o diagnóstico completo da "saúde" do processo de aprendizado da rede neural ao longo das 50 épocas. A análise destas curvas fornece evidências empíricas de que o modelo atingiu a convergência ideal, validando as escolhas de hiperparâmetros adotados.

Figura 24 – Curvas de treinamento e validação (Loss)



Fonte – Autores (2026)

5.8 Interpretação das curvas de treinamento e validação (Loss)

- **Comportamento das Funções de Perda (Loss Curves):** Os três gráficos à esquerda (boxLoss, clsLoss e dfllLoss) medem a taxa de erro do modelo. Observa-se uma regressão contínua, suave e consistente desses erros, tanto no conjunto de treinamento (linha superior) quanto no conjunto de validação (linha inferior). O aspecto mais crítico e positivo desta análise é a ausência total de overfitting (sobreajuste). Em modelos mal calibrados, a curva de perda de validação começa a subir nas épocas finais, indicando que a IA está apenas "decorando" os dados de treino. No nosso modelo, a perda de validação continua caindo em paralelo com a de treino, provando que a rede neural desenvolveu uma excelente capacidade de generalização para imagens do mundo real.
- **O Ajuste Fino Final (O Salto na Época 40):** Um detalhe técnico notável ocorre nas curvas de perda de treinamento (train/boxLoss e train/dfllLoss), onde há uma queda abrupta e benéfica por volta da época 40. Este comportamento é a assinatura visual de uma técnica avançada do algoritmo YOLO: a desativação do Data Augmentation agressivo (como o efeito Mosaic) nas últimas 10 épocas do treinamento. Sem as distorções extremas na reta final, o modelo consegue realizar um ajuste fino (fine-tuning) milimétrico nas coordenadas das caixas delimitadoras, resultando em detecções muito mais precisas. um

- **Evolução das Métricas de Desempenho (Precision, Recall e mAP):** Os gráficos à direita ilustram o ganho de "inteligência" do modelo. As curvas de Precisão, Revocação (Recall) e mAP (mean Average Precision) demonstram um crescimento logarítmico clássico e saudável. Nas primeiras 15 épocas, o modelo apresenta uma curva de aprendizado íngreme, absorvendo rapidamente os padrões visuais básicos dos EPIs (graças à eficiência do otimizador AdamW). A partir da época 30, as métricas entram em uma fase de estabilização (platô), subindo de forma mais gradual. O mAP50 atinge e se estabiliza no topo do gráfico, indicando alta confiabilidade nas detecções.

6 Conclusões

A detecção automática de Equipamentos de Proteção Individual utilizando visão computacional surge como uma importante ferramenta para auxiliar no monitoramento da segurança em ambientes industriais e de construção civil. Este trabalho demonstrou como técnicas modernas de inteligência artificial e aprendizado profundo podem contribuir para automatizar a identificação do uso de EPIs, proporcionando maior agilidade, precisão e eficiência nos processos de fiscalização e auditorias de segurança.

Ao utilizar algoritmos de detecção de objetos, como o modelo YOLO, foi possível identificar equipamentos como capacetes, coletes de segurança, máscaras, luvas e botas em diferentes cenários e condições de iluminação. A aplicação de técnicas de *data augmentation* também contribuiu significativamente para aumentar a robustez do modelo, especialmente em objetos pequenos, permitindo melhor adaptação a situações reais.

Além disso, a automatização do processo reduz a necessidade de fiscalização exclusivamente manual, auxiliando empresas na prevenção de riscos ocupacionais e no cumprimento das normas de segurança do trabalho (Questões de conformidade). Entretanto, desafios como baixa iluminação, oclusão parcial dos equipamentos, qualidade das imagens e dificuldade na detecção de objetos menores ainda representam limitações importantes para o sistema.

A integração entre visão computacional, inteligência artificial e aprendizado profundo apresenta grande potencial para evolução futura, permitindo o desenvolvimento de sistemas cada vez mais precisos, rápidos e inteligentes. Dessa forma, a utilização dessas tecnologias pode contribuir diretamente para ambientes de trabalho mais seguros, modernos e eficientes.

6.1 Limitações

Um dos principais desafios encontrados está relacionado à precisão da detecção em condições adversas, como baixa iluminação, sombras intensas, diferentes posicionamentos dos trabalhadores e oclusão parcial dos EPIs. Além disso, objetos menores, como luvas e botas, apresentaram menor taxa de confiança durante os testes realizados.

Outro fator importante é a necessidade de bases de dados extensas e diversificadas para treinamento do modelo, garantindo maior capacidade de generalização em diferentes ambientes e situações reais. A qualidade das imagens utilizadas também influencia diretamente o desempenho do sistema.

Além disso, existem limitações de hardware para o treinamento do modelo. Atualmente, o principal gargalo é a máquina virtual gratuita oferecida pelo Google Colab (GPU T4 com 16 GB de VRAM e 12 GB de RAM).

Apesar das limitações encontradas, os resultados demonstraram que o uso de visão computacional aplicada à segurança do trabalho possui grande potencial para aplicações reais.

6.2 *Trabalhos futuros*

Como trabalhos futuros, considera-se a ampliação do sistema para identificação de outros tipos de Equipamentos de Proteção Individual, como óculos de proteção e protetores auriculares. Além disso, pretende-se implementar a detecção em tempo real utilizando câmeras de monitoramento, permitindo aplicações em ambientes industriais reais.

Outro aprimoramento importante seria a utilização de modelos mais avançados de aprendizado profundo com a disponibilidade de hardware mais potente, buscando aumentar a precisão da detecção em cenários complexos e com múltiplos trabalhadores na mesma imagem.

Também considera-se a integração do sistema com plataformas de monitoramento e emissão automática de alertas em situações de não conformidade, contribuindo para processos de fiscalização mais eficientes e inteligentes.

Referências

- ABDI, H. Principal component analysis (pca). 2010. Disponível em: <https://www.utdallas.edu/~herve/Abdi-PCA2010-pretty.pdf>. Citado na página 24.
- ANTONELLO, R. Introdução a visão computacional com python e opencv. *Santa Catarina, 1a edição*, 2018. Citado 2 vezes nas páginas 32 e 33.
- ASSISTANT, M. C. Segmentação de imagens: Conceitos e aplicações. *Revista de Inteligência Artificial*, v. 10, n. 2, p. 123–137, 2024. Disponível em: <https://www.example.com/segmentacao-imagem>. Citado na página 22.
- BRADSKI, G. The opencv library. *Dr. Dobb's Journal of Software Tools*, v. 25, n. 11, p. 120–126, 2000. Citado na página 29.
- GONZALEZ, R. C.; WOODS, R. E. *Digital Image Processing*. [S.l.]: Pearson, 2008. Citado 4 vezes nas páginas 18, 19, 21 e 28.
- IBM. *IBM - O que são redes neurais convolucionais?* 2024. Disponível em: <https://www.ibm.com/br-pt/topics/convolutional-neural-networks>. Citado na página 26.
- JAMUNDÁ, T. *Reconhecimento de Formas: A Transformada de Hough*. 2000. Disponível em: <http://www.inf.ufsc.br/~aldo.vw/visao/2000/Hough/index.html>. Citado 2 vezes nas páginas 25 e 26.
- KHAN, M. U.; ANWAR, S.; MAJID, M. A survey of the recent architectures of deep convolutional neural networks. *Sensors*, v. 21, n. 1, p. 36, 2021. Disponível em: <https://www.mdpi.com/1424-8220/21/1/36>. Citado na página 18.
- LUCENA, M. M. d. Sistema de visão computacional para automação do processo de fabricação de válvula esfera tripartida. 2024. Citado na página 31.
- PIEMONTEZ. Identificação, detecção, reconhecimento e segmentação de imagem e objetos. 2022. Acesso em: 1º de maio de 2022. Disponível em: <https://visaocomputacional.com.br/identificacao-deteccao-reconhecimento-e-segmentacao-de-imagem-e-objetos/>. Citado na página 24.
- QI, Y.; YANG, Z.; SUN, W.; LOU, M.; LIAN, J.; ZHAO, W.; DENG, X.; MA, Y. A comprehensive overview of image enhancement techniques. *Archives of Computational Methods in Engineering*, v. 29, p. 583–607, 2022. Citado na página 21.
- RAUBER, J. T. Sistema de visão computacional aplicado à contagem de sementes de soja movimentadas por uma transportadora de sucção pneumática. Universidade Federal da Fronteira Sul, 2019. Citado na página 33.
- REDONDA, V.; NASCIMENTO, F.; ASSIS, W. L. Visão computacional aplicada ao modelamento de nucleação, crescimento e predição de propriedades mecânicas via método do cone causal. Citado na página 32.
- SANTOS, T. T.; BARBEDO, J. G. A.; TERNES, S.; NETO, J. C.; SOUZA, K. X. S. de. Visão computacional aplicada na agricultura. 2020. Citado na página 31.
- SERVICES, A. W. *O que é visão computacional?* 2024. Disponível em: <https://aws.amazon.com/pt/what-is/computer-vision/>. Citado na página 24.

SHU, J.; WU, X.; SUGANTHAN, P. N. Linear discriminant analysis: A survey. 2018. Disponível em: <https://link.springer.com/article/10.1007/s10462-018-9656-5>. Citado na página 24.

WANGENHEIM, A. v. *Morfologia Matemática - Visão Computacional*. 2000. Disponível em: <http://www.inf.ufsc.br/~aldo.vw/visao/2000/morfologia/morfologia.html>. Citado na página 28.

WECHSLER, H. *Computational vision*. [S.l.]: Elsevier, 2014. Citado na página 18.